

第3章 统计模式识别中的概率方法

3.1 用概率方法描述分类问题

略

3.2 几个相关的概念

贝叶斯公式: $P(\omega_j|X) = \frac{p(X|\omega_j)P(\omega_j)}{P(X)}$

3.3 最小错误概率判决准则

选择相交的那个

3.4 最小风险判决规则

$$R(\alpha_i|X) = \min_{j=1, \dots, A} \{R(\alpha_j|X)\} \Rightarrow X \in \omega_i$$

其中R为损失函数

3.5 贝叶斯统计判决规则的似然比表现形式

定义类别的似然比 $l_{1,2}(X) = \frac{p(X|\omega_1)}{p(X|\omega_2)}$, 判决阈值为 $\theta_{1,2} = \frac{P(\omega_2)}{P(\omega_1)}$, 则判定简化为 $l_{1,2}$ 和 $\theta_{1,2}$ 的比较。

最小风险判决规则: $\theta_{1,2} = \frac{(L(\alpha_1|\omega_2) - L(\alpha_2|\omega_2))P(\omega_2)}{(L(\alpha_2|\omega_1) - L(\alpha_1|\omega_1))P(\omega_1)}$

3.6 拒绝判决

可能产生拒绝判决的前提条件: $P(\omega_i|X) < \left(1 - \frac{\lambda_R}{\lambda_F}\right), \forall x \in [1, n] \Rightarrow X \in \alpha_{N+1}$

3.7 贝叶斯分类器的一般结构

取 $g_i(X) = P(\omega_i|X)$, 也就是 $g_i(X) = \frac{p(X|\omega_i)P(\omega_i)}{\sum_{j=1}^N p(X|\omega_j)P(\omega_j)}$, 或在最小风险判决规则下取 $g_i(X) = -R(\alpha_i|X)$

3.8 Neyman-Pearson判决规则

在保持 ϵ_1 一定的情况下使得 ϵ_2 最小。构造 $J = \epsilon_1 + \lambda(\epsilon_2 - \alpha) = (1 - \lambda\alpha) + \int_{\Omega_1} (\lambda p(x|\omega_2) - p(x|\omega_1))dx$

其实就是 $\frac{p(x|\omega_1)}{p(x|\omega_2)} > \lambda \Rightarrow x \in \omega_1$

3.9 最小最大判决规则

太复杂了, 餐间刻本

3.10 基于分段线性化的分类器设计

同上

3.11 正态分布下的分类器设计

多元正态分布: $p(X) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (X - \mu)^T \Sigma^{-1} (X - \mu) \right\}$

1. $\Sigma_i = \sigma^2 I$ 的情况

超平面: $W^T (X - X_0)$, 其中 $W = \mu_i - \mu_j$, $X_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\ln \frac{P(\omega_i)}{P(\omega_j)}}{(\mu_i - \mu_j)^T \Sigma^{-1} (\mu_i - \mu_j)} (\mu_i - \mu_j)$

2. $\Sigma_i = \Sigma$ 非对角阵

超平面: $W^T (X - X_0)$, 其中 $W = \Sigma^{-1}(\mu_i - \mu_j)$, X_0 一样

3. Σ_i 任意

超二次曲面

3.12 有监督情况下类条件概率密度的参数估计

极大似然估计

也就是最大似然估计, 和数理统计学的一样

需要注意的是, $\frac{\partial |\Sigma|}{\partial \Sigma} = |\Sigma|(\Sigma^T)^{-1}$

贝叶斯估计和贝叶斯学习

假定 $\lambda(\hat{\theta}|\theta)$ 为真实参数为 θ 、给出 $\hat{\theta}$ 估计时承担的风险。以下考虑 $\lambda(\hat{\theta}|\theta) = (\hat{\theta} - \theta)^2$, 得到如下定理:

- **定理3.1** θ 的贝叶斯估计量 $\hat{\theta}$ 是在给定样本 X 条件下 θ 的数学期望。或: $\hat{\theta} = \int_{\Theta} \theta p(\theta|X) d\theta$

贝叶斯学习: 和贝叶斯分布的前三个步骤类似, 最后从后验概率密度直接得到总体概率密度。

3.13 非监督情况下类条件概率密度的估计

分类未知, 最大似然方法适用于待估参数是确定未知量, 贝叶斯学习方法适用于待估参数是随机的未知量。

条件概率密度参数估计: P131 公式3.100, 要求 $P(\omega_i)$ 为已知量。

该算法可用于迭代正态分布。

3.14 类条件概率密度的非参数估计

Parzen窗函数

对每个点应用窗函数。

k_n -近邻估计法

扩张直到包含这些样本。

正交级数逼近法

用正交函数系的基函数 $\{\phi_i(X), i = 1, 2, \dots, m\}$ 表示 $\hat{p}_n(X)$, 其需要做的是确定这些函数的线性加权系数。

若选择归一化正交函数则有 $c_i = \frac{1}{n} \sum_{k=1}^n u(X_k) \phi_i(X_k)$