

根据上述元素，我们将隐马尔可夫模型下的中文分词问题表述为如下形式：

当我们观测到句子 w_1, w_2, \dots, w_n ，其中 w_i 为第 i 个汉字，我们希望找到相应的标签序列 s_1, s_2, \dots, s_n ，其中 s_i 为 w_i 对应的标签（HMMs中的一种），使得 $P(s_1, s_2, \dots, s_n | w_1, w_2, \dots, w_n)$ 概率最大。

为求解这一目标函数，需要隐马尔可夫模型的两个基本假设：

- 齐次假设：当前隐藏状态只与上一个状态有关系
 - 即 $P(s_i | s_{i-1}, s_{i-2}, \dots, s_1) = P(s_i | s_{i-1})$
- 观测独立性假设：观测值之间互相独立的，只与生成它的状态有关系
 - 即 $P(w_1, w_2, \dots, w_n | s_1, s_2, \dots, s_n) = P(w_1 | s_1) P(w_2 | s_2) \dots P(w_n | s_n)$

维特比算法的一个实现案例：

初始状态概率矩阵	T		F	
	0.6		0.4	
隐含状态转移概率矩阵		->T	->F	
	T	0.7	0.3	
	F	0.4	0.6	
观测状态概率矩阵		->X	->Y	->Z
	T	0.5	0.4	0.1
	F	0.1	0.3	0.6

问：观测到显式状态序列依次为 X、Y、Z，最可能的隐含状态序列是什么？

(1) 初始化

在 $t=1$ 时，对每一个状态 s_i (记显式状态 x 为 s_1 ， x 为 s_2)，计算状态为 s_i

观测 w_1 为 x 的概率，记此概率为 $\delta_1(s_i)$ ，则

$$\delta_1(s_i) = \pi \cdot b_i(w_1) \quad i=1,2$$

代入实际数据

$$\delta_1(T) = 0.6 \times 0.5 = 0.3$$

$$\delta_1(F) = 0.4 \times 0.1 = 0.04$$

可见，第一个隐状态为T更为合理

同理，在 $t=2$ 时，

$$\begin{aligned} \delta_2(T) &= \max_{s_{i-1}} \{\delta_1(s_{i-1}) \cdot a_{ji}\} \cdot b_j(w_2) & \psi_2(T) &= \arg \max_{s_{i-1}} \{\delta_1(s_{i-1}) \cdot a_{ji}\} \\ &= \max_{s_{i-1}} \{0.084 \times 0.7, 0.027 \times 0.4\} \times 0.1 & &= \arg \max_{s_{i-1}} \{0.084 \times 0.7, 0.027 \times 0.4\} \\ &= 0.00588 & &= 1 \end{aligned}$$

$$\delta_2(F) = 0.01512 \quad \text{此时，第二个隐状态为F的概率更高} \quad \psi_2(F) = 1$$

(3) 以 P^* 表示最优路径的概率，则

$$P^* = \max_{1 \leq i \leq 2} \delta_2(s_i) = 0.01512$$

最优路径的终点下标 i_2^* 是 $i_2^* = \arg \max_{1 \leq i \leq 2} \delta_2(s_i) = 2$

条件随机场模型 (CRF)：具有表达长距离依赖性和交叠性特征的能力。所有特征可以进行全局归一化，能够求得全局的最优解。(隐马尔可夫模型的独立性假设难以描述字词之间的复杂关联)

长短时记忆模型 (LSTM)：通过四层神经网络代替 RNN 中原有的单一神经网络层，使其拥有增加或减少信息的能力

通过结合 LSTM 与 CRF 技术，将有效利用句子级别的标记信息。• 输出的将不再是相互独立的标签，而是最佳且合理的标签序列。

基于目标函数和两个基本假设，基于隐马模型的中文分词问题转化为：

我们希望找到相应的标签序列 s_1, s_2, \dots, s_n ，使得 $\prod_{i=1}^n P(s_i | s_{i-1}) P(w_i | s_i)$ 概率最大。

针对这一问题，可采用维特比 (Viterbi) 算法进行求解：

- 初始化：对第一个字，分别以BEMS四种状态计算其概率
- 递归：对第 i 个字，遍历四种状态，先计算该状态最可能是由前一时刻的哪个状态转换而来的，再乘以该状态下得到观测值 (字) 的概率，取最大值。
- 终止：在第 n 个字时，取得到的最大概率，并得到最后一个字的状态标签。
- 回溯：由最优路径的终点向前，找到各个时刻的最优状态，还原全部标签。

• 记S是所有可能的状态的集合， $S = \{s_1, s_2\} = \{T, F\}$

• $I = (s_1, s_2, s_3)$ 是长度为3的状态序列，其对应的观测序列为 $W = (w_1, w_2, w_3) = (X, Y, Z)$

• 隐含状态转移概率矩阵为 $A = [a_{ij}]_{2 \times 2} = \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{bmatrix}$ ，其中， $a_{ij} = P(s_i = s_j | s_i = s_i) \quad i=1,2, j=1,2$

表示在时刻 i 处于状态 s_i 的条件下在时刻 $i+1$ 转移到状态 s_j 的概率。

• 观测状态概率矩阵为 $B = [b_i]_{2 \times 3} = \begin{bmatrix} 0.5 & 0.4 & 0.1 \\ 0.1 & 0.3 & 0.6 \end{bmatrix}$ ，其中， $b_i(k) = P(w_i = v_k | s_i = s_i) \quad i=1,2, j=1,2$

表示在时刻 i 处于状态 s_i 的条件下生成观测 v_k 的概率。

• π 是初始状态概率向量： $\pi = (\pi_1, \pi_2) = (0.6, 0.4)$ ，其中， $\pi_i = P(s_1 = s_i) \quad i=1,2$

表示在时刻 $i=1$ 处于状态 s_i 的概率

(2) 在 $t=2$ 时，对每一个状态 s_i ，求在 $t=1$ 时状态为 s_j 观测为 x 并在 $t=2$ 时状态为 s_i 观测 w_2 为 y 的路径的最大概率，记此最大概率为 $\delta_2(s_i)$ ，则

$$\delta_2(s_i) = \max_{s_{i-1}} \{\delta_1(s_{i-1}) \cdot a_{ji}\} \cdot b_j(w_2)$$

同时，对每个状态 s_i ，记录概率最大路径的前一个状态 s_j ，所对应的下标 j ：

$$\psi_2(s_i) = \arg \max_{s_{i-1}} \{\delta_1(s_{i-1}) \cdot a_{ji}\} \quad i=1,2$$

$$\begin{aligned} \text{计算: } \delta_2(T) &= \max_{s_{i-1}} \{\delta_1(s_{i-1}) \cdot a_{ji}\} \cdot b_j(w_2) & \psi_2(T) &= \arg \max_{s_{i-1}} \{\delta_1(s_{i-1}) \cdot a_{ji}\} \\ &= \max \{0.3 \times 0.7, 0.04 \times 0.4\} \times 0.1 & &= \arg \max \{0.3 \times 0.7, 0.04 \times 0.4\} \\ &= 0.084 & &= 1 \\ \delta_2(F) &= 0.027 & & \psi_2(F) = 1 \end{aligned}$$

显然，第二个隐状态为T的概率仍然高于F的概率

(4) 由最终路径的终点下标 i_2^* ，逆向找到 i_1^*, i_2^* ：

在 $t=2$ 时， $i_2^* = \psi_2(s_{i_2^*}) = \psi_2(F) = 1$

在 $t=1$ 时， $i_1^* = \psi_1(s_{i_1^*}) = \psi_1(T) = 1$

于是求得 $(i_1^*, i_2^*, i_3^*) = (1, 1, 2)$

最优状态序列 $I^* = (s_1, s_2, s_3) = (T, T, F)$